

模式识别经典模型教材小册子

第 7-9 项：感知机、GMM、HMM

学习目标：本小册子从生活化场景出发，依次讲清三个经典模型的直觉、公式、运行流程、典型应用与局限。读者不需要先背公式，只要先理解每个模型在解决什么问题。




图 0-1 第 7-12 项模型的三条主线，本小册子聚焦前三个模型。

模型	一句话理解	主要任务	本章重点
感知机	分错就修正的线性分类器	二分类、线性边界学习	权重更新与线性可分
GMM	多个高斯团块的概率混合	软聚类、密度估计	EM 算法与软归属
HMM	隐藏状态生成观测序列	序列识别、路径解码	三组概率与三类问题

0. 阅读导引：先记住三个故事

模式识别听起来像一门很抽象的课，但这三个模型都可以先从生活故事进入。感知机像拿尺子分水果，GMM 像根据味道猜糖果来自哪台机器，HMM 像根据脚印猜一个人走过哪些房间。

这三个故事背后，对应的是三种不同的机器学习思路：用边界分开样本，用概率解释数据来源，用时间顺序推断隐藏状态。

故事	模型	机器真正学的东西	一句话记忆
尺子分水果	感知机	一条能分开两类样本的直线或平面	分错就把边界挪一挪
猜糖果来源	GMM	多个概率团块的位置、形状和比例	一个样本可以像多个群体
看脚印猜路线	HMM	隐藏状态如何随时间变化并产生观测	看见表面现象，推测背后路线

0.1 本文的公式怎么看

公式只承担“把故事变成计算规则”的作用。阅读时可以先看公式下面的中文解释，知道每个符号代表什么，再回到公式本身。

符号	通俗理解	常见位置
x	一个样本的特征，比如颜色、重量、声音片段	三个模型都会出现
w	感知机里每个特征的重要程度	感知机
μ, Σ	GMM 中一个概率团块的中心和形状	GMM
π, a, b	HMM 的初始概率、转移概率、发射概率	HMM

0.2 学习时可以问自己的三个问题

1. 这个模型把现实问题想象成什么故事？
2. 模型最后学到的是边界、团块，还是状态路线？
3. 如果数据变复杂，这个模型最先暴露的短板是什么？

1. 感知机 (Perceptron)

一句话定位：感知机是一种线性二分类模型。它用一条线、一个平面或一个高维超平面把样本分成两类，并在分错样本时调整边界。

1.1 核心直觉

可以把感知机想象成一位刚学会分类的小老师。桌上有苹果和橘子，小老师拿一把尺子在桌面上画线：线左边算苹果，线右边算橘子。如果它把一个苹果分到橘子那边，就把尺子轻轻挪一下；如果把橘子分到苹果那边，也再挪一下。

所以，感知机最重要的想法很简单：先画一条分界线，错了就改，改到尽量少出错。二维数据中这条界线是一条直线；三维数据中是一个平面；维度更高时叫超平面。




图 1-1 感知机根据误分类样本调整线性边界。

如果只记一句话，就是：感知机像一个会改错的分类小老师，分错一次就把线挪一点。

1.2 必要公式

$$s = \mathbf{w}^T \mathbf{x} + b$$

$$f(\mathbf{x}) = \text{sign}(s)$$

$$w \leftarrow w + \eta y_i x_i, \quad b \leftarrow b + \eta y_i$$

x 是样本的特征，比如“颜色有多红、重量有多大”； w 表示每个特征有多重要； b 像一个整体门槛； η 决定每次改错时挪多远。公式真正想说的是：机器先打分，再看正负号；如果分错，就按正确方向改一下。

1.3 生活例子：水果分类

假设有一张表，每个水果只记录两个数字：颜色偏红的程度和重量。苹果通常更红一些，橘子通常颜色和重量分布不同。感知机会在这张二维表上画出一条线，线的一边叫“苹果”，另一边叫“橘子”。

刚开始这条线可能画得很差。只要发现一个苹果被分到了橘子那边，模型就把线往能容纳这个苹果的方向挪一点；如果橘子被分到了苹果那边，就往相反方向挪一点。训练过程就是不断纠正这些小错误。

1.4 适合放在课本里的伪代码

4. 准备一批已经标好类别的样本。
5. 先随便给一组权重 w 和偏置 b 。
6. 拿一个样本来测试，看看当前模型是否分对。
7. 分对就继续看下一个样本；分错就更新 w 和 b 。
8. 重复多轮，直到错误明显减少。

1.5 例题

例题：小老师一开始完全不会分，设 $w=(0,0)$ ， $b=0$ ，学习率 $\eta=1$ 。现在来了一个“苹果”样本 $x=(2,1)$ ，真实标签 $y=+1$ 。小老师分错了，应该怎么改？

解答：更新后 $w=(0,0)+1*(+1)*(2,1)=(2,1)$ ， $b=0+1*(+1)=1$ 。下一次再遇到这个样本时，

$s=2*2+1*1+1=6$ ，模型会判为正类。

1.6 更多生活例子

感知机适合解释那些“差不多能用一条线分开”的问题。它不一定是最强模型，但非常适合帮助读者理解机器如何把经验变成分界线。

场景	样本特征	两类标签	分界线的含义
垃圾邮件识别	促销词数量、可疑链接数量、标题夸张程度	垃圾邮件 / 正常邮件	超过某个风险组合就判为垃圾邮件
运动项目推荐	身高、爆发力测试成绩、耐力测试成绩	适合短跑 / 适合长跑	不同身体条件对应不同运动方向
图书分类	关键词中科普词比例、故事词比例	科普书 / 故事书	关键词组合更偏向哪类书

1.7 课堂讲解稿

讲感知机时，可以先不急着想公式。先让读者在纸上画两堆点，然后尝试画一条直线把它们分开。画错了没有关系，只要看到哪个点被分错，就把线往那个点正确的一边移动。这个过程就是感知机学习的图像化版本。

等读者接受“线会移动”之后，再引入权重 w 和偏置 b 。权重决定线的方向，偏置决定线整体往哪边平移。学习率 η 则像尺子的步长：步长太小，改得慢；步长太大，容易改过头。

1.8 常见误区

- 误区一：感知机什么边界都能学。实际上，单层感知机只能学直线、平面或高维超平面这类线性边界。
- 误区二：分对训练集就一定能分对新样本。训练集只是一部分例子，新样本可能落在边界附近。
- 误区三：学习率越大越好。学习率太大时，边界可能来回跳，反而不稳定。

1.9 习题

- 如果苹果和橘子混成一个圆圈套一个圆圈，一条直线还能分开吗？这能说明感知机的什么局限？
- 如果每次改错时尺子挪得特别远，可能会发生什么？
- 把“是否有促销词、是否有可疑链接、邮件长度”当作三个特征，解释每个权重像什么。
- 在二维平面上画 6 个正类点和 6 个负类点，尝试手动画出一条分界线，并标出最容易被分错的点。

1.10 小实验

实验目标	数据建议	操作步骤	观察指标
观察线性边界如何随错误样本移动	二维人工数据，两类点大致可线性分开	用 Python 生成散点；手写感知机更新；每轮画出边界	错误数、边界位置、是否收敛

1.11 本节小结

感知机的关键不是复杂公式，而是“分错就修正”。它把模式识别中的分类问题转化为寻找线性边界的问题，是理解神经网络和线性模型的起点。

2. 高斯混合模型（GMM）

一句话定位：GMM 认为数据来自多个高斯分布的叠加，每个样本可以用概率方式属于不同成分。

2.1 核心直觉

可以把 GMM 想象成一袋混在一起的糖果。糖果可能来自草莓味机器、葡萄味机器和柠檬味机器。我们现在只看到每颗糖的颜色和味道，不知道它到底是哪台机器做的。GMM 的任务，就是猜“每颗糖更像来自哪台机器”。

如果一颗糖颜色介于草莓和葡萄之间，GMM 不会粗暴地说它一定是草莓味，而可能说：它 60% 像草莓机器做的，35% 像葡萄机器做的，5% 像柠檬机器做的。这就是软归属。




图 2-1 GMM 用多个椭圆状高斯成分解释数据分布。

所以，GMM 的重点不是“强行分堆”，而是“带着不确定性分堆”。这很适合真实世界，因为很多东西本来就不是非黑即白。

2.2 必要公式

$$p(x) = \pi_1 \cdot N_1(x) + \pi_2 \cdot N_2(x) + \dots + \pi_K \cdot N_K(x)$$

责任度 $\gamma(i,k) = \text{第 } k \text{ 个团块的贡献} \div \text{所有团块的总贡献}$

公式里的每个 $N_k(x)$ 可以理解为一个“糖果制造机器”对样本 x 的解释能力。 μ_k 是这台机器最常做出的典型糖果， Σ_k 描述糖果可能散开的范围和方向， π_k 表示这台机器在整袋糖果里占多大比例。 γ_{ik} 叫责任度，可以理解为“第 k 台机器对第 i 颗糖有多大嫌疑”。

2.3 生活例子：商场顾客分群

商场可以记录顾客的两个数字：一年消费金额和到店次数。直接看散点图时，顾客可能混在一起；GMM 会尝试把他们解释成几个重叠的群体，例如“经常来且消费高的核心顾客”“不常来但偶尔买很多的顾客”“低频低消费的普通顾客”。

有些顾客落在两个群体之间。GMM 不会强行说他只属于某一类，而是给出一组概率。这样，商场可以对边界顾客采用更柔性的策略，例如既推送高价值商品，也保留普通优惠券。

2.4 EM 算法怎么理解

- 9. E 步：根据当前模型，估计每个样本属于每个成分的概率。
- 10. M 步：根据这些概率，重新计算每个成分的位置、形状和权重。
- 11. 两步交替进行，模型逐渐贴合数据分布。

E 步像是“先猜每颗糖来自哪台机器”；M 步像是“根据这些猜测，重新调整每台机器的典型口味”。一开始可能猜得不准，但反复几轮后，每台机器的位置和范围会越来越合理。

2.5 例题

例题：一颗糖对草莓机器和葡萄机器的责任度分别是 0.75 和 0.25。如果只做硬分类，它会被分到哪一类？如果做软聚类，这两个数字又告诉我们什么？

解答：硬分类会把它分到草莓机器。但软聚类还告诉我们：它不是百分百草莓，也有 25% 像葡萄。这种“不确定性”有时比单纯给一个类别更有用。

2.6 更多生活例子

GMM 特别适合那些“看起来是一团，其实由多个来源混合而成”的问题。它的优势不是强行贴标签，而是告诉我们一个样本与每个来源的相似程度。

场景	样本特征	可能的高斯成分	GMM 的帮助
班级身高分布	身高、体重	不同年龄段或不同生长阶段学生	解释为什么一个班级可能不是单峰分布

音乐用户分群	听歌时长、收藏数量、 跳过比例	深度用户、随听用户、 探索型用户	给边界用户保留多种推 荐策略
机器异常检测	温度、振动、噪声	正常工况、轻微异常、 严重异常	低概率样本可作为预警 信号

2.7 如何理解 K 的选择

GMM 需要提前设定成分数 K 。 K 可以理解为“我们允许模型假设有几台糖果机器”。如果 K 太小，不同来源会被硬塞在一起；如果 K 太大，模型可能把偶然噪声也当成一台新机器。

实际使用时，可以比较不同 K 下的模型效果，也可以结合业务常识。例如顾客分群不一定越细越好，分得太细反而难以解释和行动。课程学习中，重点是理解 K 影响模型解释方式，而不是记住某一个固定答案。

2.8 课堂讲解稿

讲 GMM 时，可以先让读者观察一张散点图：有些点明显属于左边一团，有些点明显属于右边一团，但中间有一些点很难判断。普通硬分类会强行给这些点贴一个标签，GMM 则会说它同时有几种可能。

这正是概率模型的价值：它不仅给答案，还表达不确定性。很多真实决策不是“是或不是”，而是“更像哪一种，以及有多像”。

2.9 常见误区

- 误区一：GMM 只是 K-Means 的复杂版本。GMM 的重点是概率解释，能表达一个样本同时像多个群体。
- 误区二：成分数 K 越大越好。 K 太大时，模型可能把噪声也当成独立群体。
- 误区三：椭圆只是一张图。椭圆背后对应协方差矩阵，表示数据在不同方向上的散开程度。

2.10 习题

- 如果糖果有三种来源，却只让 GMM 找两个团块，会发生什么？

- 如果让 GMM 找太多团块，它会不会把一些偶然的小差异也当成一种来源？
- 如果一颗糖不像任何一台机器做出来的，它为什么可能是异常样本？
- 举一个现实中的混合分布例子，并说明每个高斯成分可能代表什么人群或状态。

2.11 小实验

实验目标	数据建议	操作步骤	观察指标
比较硬聚类与软聚类的差别	二维混合高斯数据，三个不同方向的簇	分别运行 K-Means 与 GaussianMixture；画出簇中心、椭圆和责任度	AIC/BIC、责任度、边界样本归属

2.12 本节小结

GMM 的核心价值是用概率方式描述“混合”。它不仅告诉我们样本属于哪个群体，还告诉我们这种判断有多确定。

3. 隐马尔可夫模型（HMM）

一句话定位：HMM 用于序列数据。它假设背后存在一串看不见的状态，这些状态按时间变化，并生成我们能观察到的信号。

3.1 核心直觉

可以把 HMM 想象成“看脚印猜路线”的游戏。一个小朋友在几个房间里走来走去，但我们没有看到他本人，只看到了地上的脚印。房间就是隐藏状态，脚印就是观测。我们要根据一串脚印，猜他最可能走过哪些房间。

很多任务都像这个游戏：语音识别时，我们看见的是声音波形，却想知道背后的音素或词；天气例子里，我们看见某人有没有带伞，却想猜当天是晴天、阴天还是雨天。




图 3-1 HMM 的隐藏状态链与观测序列。

所以，HMM 的重点是：看见一串表面现象，推测背后一串看不见的状态。

3.2 三组关键概率

$\pi_i = P(\text{一开始在状态 } i)$
$a_{ij} = P(\text{下一步到状态 } j \mid \text{当前在状态 } i)$
$b_j(o) = P(\text{看到观测 } o \mid \text{当前在状态 } j)$

用脚印故事来理解：初始概率表示小朋友一开始在哪个房间的可能性；转移概率表示他从一个房间走到另一个房间的可能性；发射概率表示某个房间留下某种脚印的可能性。

3.3 生活例子：天气和带伞

真实天气可能是晴天、阴天或雨天，但我们不一定直接看到天气记录，只看到一个人连续几天有没有带伞。如果连续三天都带伞，我们会猜这几天可能更容易下雨；如果某天没带伞，我们又会重新调整判断。

在这个例子中，天气是隐藏状态，带伞与否是观测。HMM 的作用，就是把“连续几天有没有带伞”这串表面现象，变成对“连续几天天气如何”的概率推断。

3.4 三个经典问题

问题	在问什么	典型算法
评估	给定模型和观测序列，这段观测出现的概率是多少？	前向算法
解码	给定观测序列，最可能的隐藏状态路径是什么？	Viterbi 算法
学习	只有观测序列时，如何估计模型参数？	Baum-Welch 算法

3.5 例题

例题：在“看脚印猜路线”中，我们看到的序列是：湿脚印、湿脚印、干脚印。请问隐藏状态和观测分别是什么？

解答：观测是我们真正看到的脚印类型，比如湿脚印、干脚印；隐藏状态是小朋友走过的房间，比如水池房、走廊、教室。HMM 想做的事，就是根据脚印序列猜最可能的房间路线。

3.6 更多生活例子

HMM 适合讲解所有“表面看到一串东西，背后其实有一串状态”的问题。它的价值在于把时间顺序纳入模型，而不是把每个样本孤立地看待。

场景	观测	隐藏状态	HMM 的帮助
语音识别	连续声音特征	音素或词内部发音阶段	根据声音序列推断说了什么
输入法联想	已经输入的拼音或字词	用户想表达的词语序列	根据上下文猜下一步输入
设备故障诊断	温度、振动、电流变化	正常、磨损、故障等内部状态	根据传感器序列提前预警

3.7 一个小型状态表

为了让 HMM 更具体，可以想象一个只有两个隐藏状态的天气模型：晴天和雨天。观测只有两种：带伞和不带伞。模型需要知道三类信息：第一天更可能是什么天气，晴天之后更可能还是晴天还是变成雨天，雨天时带伞的可能性有多大。

项目	示例数值	含义
初始概率	晴天 0.6，雨天 0.4	第一天更可能是晴天
转移概率	晴天后仍晴天 0.7，转雨天 0.3	天气有连续性，但也可能变化
发射概率	雨天带伞 0.9，晴天带伞 0.2	不同天气会产生不同观测

3.8 课堂讲解稿

讲 HMM 时，可以先问一个问题：如果只看一个人今天带不带伞，能不能准确知道今天是否下雨？通常不能。但如果连续看很多天，就会得到更多线索。HMM 正是利用这种连续线索来推断隐藏状态。

它和普通分类器的区别在于，普通分类器常常把每个样本单独判断，而 HMM 会把前后顺序联系起来。前一天是什么状态，会影响后一天的状态；某一天的状态，又会影响那一天能看到什么观测。

3.9 常见误区

- 误区一：隐藏状态等于看不见的标签。更准确地说，隐藏状态是一串随时间变化、并能产生观测的内部过程。
- 误区二：HMM 只用于天气例子。天气只是入门例子，语音识别、词性标注、手势识别也可以用类似思想理解。
- 误区三：只看上一个状态永远够用。现实任务可能存在更长的依赖，这也是 HMM 的重要局限。

3.10 习题

- 在天气和带伞例子里，哪个是隐藏状态？哪个是观测？
- 为什么只看今天有没有带伞，可能还不如看连续三天有没有带伞？
- 如果小朋友可能记得很久以前走过哪里，只看上一个房间会不会太简单？这说明 HMM 有什么局限？
- 给出一个你熟悉的序列任务，分别写出它的隐藏状态和观测。

3.11 小实验

实验目标	数据建议	操作步骤	观察指标
用 Viterbi 解码最可能状态路径	手工构造天气状态和带伞观测序列	设置初始、转移、发射概率；输入观测序列；输出最可能天气序列	路径概率、预测状态、与直觉是否一致

3.12 本节小结

HMM 把序列识别拆成“隐藏状态”和“可见观测”。看懂这两层结构，就能理解它为什么适合处理语音、文本、动作和故障这类随时间展开的问题。

4. 三个模型的横向比较

模型	类型	核心思想	适合问题	主要局限
感知机	判别式线性分类	分错就修正边界	线性二分类、神经网络入门	只能表达线性边界
GMM	生成式概率模型	多个概率团块混合产生数据	软聚类、密度估计、异常检测	需指定成分数，对初始化敏感
HMM	序列概率模型	隐藏状态按时间生成观测	语音、文本、动作、故障序列	难表达长期依赖

这三个模型分别代表三种思路：感知机关注分类边界，GMM 关注概率分布的混合，HMM 关注序列背后的状态变化。它们已经不是所有工业任务中的最前沿工具，但仍然是理解现代机器学习的重要地基。

5. 如何选择模型

学习模型时，很容易把注意力放在名字和公式上。但真正做题或做项目时，更重要的是先判断问题属于哪一类。下面的判断顺序可以帮助读者快速选择合适的思路。

- 12. 如果目标是把样本分成两类，并且用一条线大致能分开，可以先想到感知机。
- 13. 如果数据看起来由多个群体混合而成，并且希望保留不确定性，可以先想到 GMM。
- 14. 如果样本按时间排列，前后顺序很重要，而且背后有看不见的状态，可以先想到 HMM。
- 15. 如果三个条件都不明显，先画图、看数据结构，再决定模型。

提问方式	优先考虑	理由
能不能画一条边界分开？	感知机	它直接学习分类边界
是不是多个来源混在一起？	GMM	它解释数据来自多个概率团块
是不是一串连续过程？	HMM	它利用状态转移和观测序列

6. 一页式学习路线

第一次学习时，可以按“故事、图像、公式、例题、实验”的顺序走。这个顺序比直接背定义更稳，因为每一步都在回答一个具体问题。

步骤	要做什么	完成标志
故事	用生活例子解释模型	不用公式也能说出模型在做什么
图像	看边界、椭圆、状态链	能指出图中每个部分代表什么
公式	只记必要公式	能解释符号含义，不机械背诵
例题	手算或口头推理一次	能把模型步骤讲完整

实验	用小数据跑一遍	能观察模型输出和局限
----	---------	------------

7. 综合复习题

16. 比较感知机与 GMM：一个为什么叫判别式模型，另一个为什么叫生成式模型？
17. 如果一个任务既有类别标签，又希望解释数据来源的不确定性，应该优先考虑哪类思想？
18. 请举一个 HMM 比普通分类器更合适的任务，并说明原因。
19. 任选一个模型，说明它在现代深度学习系统中仍然保留的思想价值。
20. 把一个“学生成绩分析”问题分别改写成感知机、GMM、HMM 可以处理的版本。

8. 参考答案提示

下面不是唯一答案，而是帮助检查理解方向是否正确。只要解释能够自洽，并且能对应模型思想，就可以认为掌握了核心内容。

题目	答题要点
感知机与 GMM 的区别	感知机直接学分类边界，关心如何判别；GMM 假设数据由多个分布产生，关心数据来源和概率。
不确定性任务	优先考虑概率模型，如 GMM，因为它能输出软归属，而不是只给硬标签。
HMM 的适用性	只要任务有时间顺序、隐藏状态和观测序列，就比孤立分类更适合 HMM 思路。
学生成绩分析	感知机可判断及格/不及格；GMM 可发现学习群体；HMM 可描述一学期学习状态变化。

9. 学习小结

- 感知机像一把会调整位置的直尺，适合学习清楚的分类边界。

- GMM 像几台不同口味的糖果制造机共同解释数据，适合处理来源不唯一、边界不清楚的问题。
- HMM 像根据脚印猜路线，适合处理有时间顺序、背后状态看不见的问题。
- 学习这三个模型时，可以先问三个问题：样本有没有标签，类别边界清不清楚，数据有没有先后顺序。
- 真正理解模型，不只是记住公式，而是能把生活问题翻译成模型能处理的语言。

10. 参考文献与延伸阅读

21. Richard O. Duda, Peter E. Hart, David G. Stork. Pattern Classification.
22. Christopher M. Bishop. Pattern Recognition and Machine Learning.
23. Tom M. Mitchell. Machine Learning.
24. Kevin P. Murphy. Machine Learning: A Probabilistic Perspective.
25. Lawrence R. Rabiner. A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition.
26. scikit-learn User Guide: Perceptron, Gaussian Mixture Models, and model evaluation examples.