



廈門大學

## 2025-2026 学年春季学期期末论文

课程名称：自然辩证法概论

班级：X班

学院：

专业：

年级:

姓名:

学号:

2026 年 6 月

# 从一次多模态模型复现实验看科研中的模型、证据与责任

**摘要：** 在专业学习和科研训练中，最能改变我对科学理解的一次经历，并不是第一次跑通某个模型，也不是看到指标显著上涨，而是在复现一个多模态智能任务时，发现“看似成功”的实验结果经不起进一步追问。模型在公开验证集上给出了不错的分数，但当我把样本逐条打开、检查数据分布、错误类型和评价指标时，才意识到结果背后混杂着数据偏差、提示词设计、检索噪声和评价方式等多重因素。这个经历使我重新理解自然辩证法中关于实践、认识、系统联系和社会责任的思想：科学认识不是从数据到结论的直线推导，而是在实践中不断暴露矛盾、修正假设、重构证据链的过程。本文以这一科研经历为线索，讨论人工智能研究中模型与现实对象之间的关系、科学方法论中的可复现性与证据意识，以及技术成果进入社会场景时必须承担的责任。由此可以看到，越是复杂的现代技术研究，越需要把工具理性、批判精神和社会价值统一起来。

**关键词：** 自然辩证法；人工智能；科学方法论；可复现性；科学社会责任

## 正文

进入研究生阶段以后，我接触较多的是人工智能、机器学习和多模态模型相关的任务。刚开始做这类工作时，我对科研的想象比较朴素：选择一个方向，

阅读论文，配置环境，训练模型，然后用指标证明方法有效。这样的理解并非完全错误，因为现代科学研究确实越来越依赖严密的工程流程和量化评价。但真正让我感到难忘的一次经历，恰恰发生在这个流程看起来已经顺利完成之后。那次我尝试复现并改进一个多模态任务的方案，目标是让模型同时理解文本和图像材料，并在给定问题上生成更可靠的判断。经过若干轮调参和提示词修改，线上或本地评价指标一度出现提升。按照最直接的想法，这似乎意味着方案有效，甚至可以进一步包装为“改进方法”。可是当我继续分析错误样本时，事情变得没有那么简单。

我发现，一部分分数提升并不来自模型真正理解了图文之间的深层关系，而是来自若干偶然因素的叠加。有些样本的答案可以从文本表面词中猜出，图像信息几乎没有发挥作用；有些样本被检索模块带入了错误上下文，模型却因为语言表达流畅而掩盖了推理缺陷；还有一些样本的评价指标只关注最终字符串是否接近标准答案，没有充分检查中间理由是否可靠。更麻烦的是，当我换一组数据、换一种提示方式，原先看似稳定的提升又会下降。这种反复让我第一次明显感受到，科研中最难的不是让某个数值变大，而是判断这个数值究竟

意味着什么。它究竟反映了方法进步，还是反映了数据集漏洞、评价偏差或偶然调参？

从自然辩证法的角度看，这个经历首先改变了我对“自然观”或“对象观”的理解。人工智能研究的对象不是孤立存在的模型代码，也不是抽象意义上的数据集，而是由现实问题、数据采集、模型结构、训练过程、评价指标和应用场景共同构成的复杂系统。系统内部各部分相互制约，任何一个环节的变化都可能改变最后呈现出的“性能”。如果只盯住单一指标，就容易把局部现象误认为整体规律。恩格斯在讨论自然界联系时强调事物处于普遍联系和发展变化之中，这种思想放在今天的技术研究中仍然有启发意义[1]。在多模态模型任务里，图像、文本、模型、算力和用户需求并不是彼此无关的模块，而是共同塑造结果的条件。模型表现不是单纯由算法公式决定的，它还受到数据来源、标注方式、任务定义和社会使用目的的影响。

这也让我意识到，所谓“模型理解现实”，并不是现实对象被模型原样复制。模型只能在特定表示方式中把现实转化为可计算的结构。图像被压缩为特征，文本被切分为词元，复杂情境被写成输入提示，人的判断被简化成标签或评分。

这样的抽象是科学研究不可避免的步骤，没有抽象就没有计算和比较；但抽象同时意味着舍弃。研究者必须清楚自己舍弃了什么，不能把模型输出直接等同于现实本身。比如，一个模型在医学图像、司法文本或教育评价中给出判断时，它的“高准确率”并不必然意味着它理解了病人的身体、案件的具体处境或学生的成长过程。它只是通过训练数据和目标函数学到了某种统计关联。承认这种差距，并不是否定人工智能的价值，而是防止我们把工具能力神化。

这次复现实验对我影响更大的，是科学方法论层面的反思。过去我容易把科研方法理解为一套线性步骤：提出假设，设计实验，得到结果，写出结论。但真实科研更像是在不确定性中反复逼近问题。波普尔强调科学理论需要经受批判和可能的证伪[2]，库恩则指出科学共同体的范式会影响研究者提出问题和解释现象的方式[3]。在我的经历中，模型分数提升本身只是一个现象，它不能直接证明方法可靠。只有当这个现象能够经受更多反事实检查、消融实验、错误分析和跨数据验证时，它才逐渐获得解释力。换言之，科研不是寻找最有利于自己观点的证据，而是主动寻找可能推翻自己结论的证据。

这个认识在人工智能研究中尤其重要。由于深度学习模型规模大、参数多、

训练过程复杂，很多结果具有较强的经验性。一次实验的成功可能来自随机种子，来自数据泄漏，来自隐藏的实现细节，也可能来自计算资源差异。如果研究者只报告最漂亮的结果，而不说明实验条件、失败尝试和适用边界，就会削弱科学共同体进一步验证和积累知识的可能性。可复现性因此不仅是一种技术规范，也是一种科学伦理。它要求研究者把结论放回可以检查的实践链条中，让别人能够理解结果从哪里来、在什么条件下成立、在哪些情况下可能失效。

对我来说，那次复现中最有价值的收获不是最终分数，而是逐渐形成了记录环境、固定随机种子、保存中间输出、检查样本错误和写清实验边界的习惯。

自然辩证法强调实践是认识的来源和检验标准。这个命题在课堂上看似抽象，但在科研训练中非常具体。没有实际运行模型，我不会知道论文描述与代码实现之间存在多少细节差异；没有打开错误样本，我不会知道指标背后有多少复杂原因；没有尝试复现实验，我也不会真正理解“方法有效”这四个字需要多谨慎。实践并不只是验证已有理论的最后环节，它会反过来推动我们重新提出问题。比如，在实验早期，我的问题是“怎样提高分数”；后来问题变成“分数提升来自哪些机制”；再后来又变成“什么样的证据足以支持一个关于模型能力

的主张”。问题层次的变化，正是认识深化的过程。

在这个过程中，矛盾分析也很有帮助。人工智能研究里存在许多张力：模型规模越大，能力可能越强，但解释成本也越高；数据越多，覆盖面可能越广，但偏见和噪声也可能被放大；评价越自动化，效率越高，但越可能忽视真实使用中的复杂判断；追求快速迭代可以推动创新，却也可能诱导研究者忽略长期可靠性。这些矛盾不能靠简单选择一端来解决，而要在具体条件中寻找平衡。

以多模态任务为例，如果模型回答错误，原因可能来自视觉编码不足，也可能来自语言先验过强，还可能来自题目本身含混。只有把矛盾具体化，才能设计有效的实验，而不是笼统地说“模型不够好”。

我后来逐渐意识到，科研训练中的许多细节其实都是这种矛盾分析的具体化。比如，做消融实验看似只是把某个模块去掉再比较分数，但它真正要回答的是“整体能力由哪些条件共同生成”；做错误样本归类看似只是整理失败案例，但它真正要回答的是“同一个结果背后是否存在不同机制”；写实验日志看似只是工程习惯，但它真正要保证的是认识过程能够被回溯。过去我容易把这些工作看成论文正式结果之外的辅助劳动，甚至觉得它们耗时、琐碎、没有成就感。

经历那次复现以后，我才理解这些劳动恰恰构成科学结论的基础。没有这些中间环节，所谓结果就像脱离了生成过程的孤立数字，很难支撑严肃判断。

这种反思也改变了我对“创新”的看法。在人工智能领域，创新常常被表达为更大的模型、更复杂的结构、更高的分数或更新的概念。但从科学方法论看，创新并不只等于形式上的新，也包括对问题的重新界定、对证据标准的提高、对失败原因的解释和对适用边界的澄清。有时，一个诚实的负结果比一个不稳定的正结果更有知识价值；一个清楚说明局限的实验报告，比一个夸大能力的技术展示更接近科学精神。自然辩证法强调事物的发展包含否定之否定的过程，这并不是简单地推翻过去，而是在批判和扬弃中获得更高层次的认识。对我而言，复现实验中的多次失败并不是绕路，而是把我从表层指标推进到机制理解的必要环节。

这次经历还让我思考科学与社会的关系。人工智能并不是只停留在实验室里的技术，它正在进入搜索、教育、医疗、金融、司法辅助、科研生产等场景。模型的错误不再只是排行榜上的扣分，而可能影响人的判断、资源分配和公共信任。默顿讨论科学共同体规范时提到普遍主义、公有性、无私利性和有组织

的怀疑[4]。这些规范提醒我，科研工作不应只服务于个人发表或竞赛排名，也要服务于公共知识的可靠增长。当人工智能模型被包装为“智能助手”或“自动决策系统”时，研究者和开发者更需要说明系统能力边界，避免让用户把概率性输出误认为确定性结论。

在复现实验中，我曾经遇到一种诱惑：如果只展示少数成功案例，模型看起来非常聪明；如果只报告最好的一组参数，方法看起来非常有效；如果把失败样本放在附录甚至不提，论文叙事会显得更顺滑。但这种顺滑恰恰可能遮蔽科学问题。现代人工智能研究的社会影响越大，越不能把技术叙事建立在选择性展示之上。Bender 等人曾提醒，大规模语言模型可能带来环境成本、数据偏见和拟人化误解等风险[5]；Mitchell 也指出，机器学习系统需要在真实社会背景中评估其局限[6]。这些讨论说明，技术能力和社会责任不能分开。一个负责任的研究者既要追求性能，也要追问性能在何处成立、对谁有利、可能伤害谁、如何被监督。

我也由此更能理解“科学共同体”在现代科研中的作用。个人研究者很难凭一次实验完全证明某个复杂模型的能力，可靠知识往往需要不同研究者在不同

环境、不同数据、不同评价标准下反复检验。公开代码、公开数据处理流程、说明实验限制、接受同行质疑，这些做法并不是给科研设置障碍，而是在帮助知识摆脱个人经验的局限。尤其在人工智能研究中，很多系统具有黑箱性和资源门槛，如果只有少数机构能够训练和验证模型，普通研究者只能被动接受结论，科学共同体的批判功能就会被削弱。因此，复现工作虽然不如提出新模型那样显眼，却在维护科学知识的公共性方面具有重要意义。

这种责任意识并不意味着科研要变得保守。相反，它会促使创新更加扎实。真正有价值的突破不只是提出一个看起来新颖的模型名称，而是在更清楚的问题意识、更可靠的证据链和更可解释的边界中推进知识。对人工智能专业学生而言，学习自然辩证法的意义也正在这里：它不是在技术之外附加一层口号，而是帮助我们理解技术活动本身的哲学基础。为什么要做消融实验？因为我们需要分析复杂系统中各因素的作用。为什么要重视负结果？因为认识是在矛盾暴露和修正中发展的。为什么要关注社会影响？因为科学技术从来不是脱离人的实践活动而孤立存在的。

回看那次多模态模型复现实验，我最初以为自己要解决的是一个工程问题，

最后却发现它同时也是一个认识论问题 and 价值问题。工程上，我学会了更细致地控制变量、分析错误和保存证据；认识论上，我意识到模型输出与现实对象之间始终存在表示和解释的距离；价值上，我开始理解科研结论进入社会传播后会产生怎样的信任关系。这个过程使我从“相信指标”转向“追问指标”，从“追求结果”转向“理解结果”。这种转变虽然不如一次显著的算法突破那样醒目，却是科研训练中更深层的成长。

因此，如果要概括这件事带给我的自然辩证法思考，我认为核心在于三点相互贯通的认识。第一，科学对象是系统性的，不能用孤立指标替代整体理解；第二，科学方法是批判性的，可靠结论必须经受实践、复现和反证的检验；第三，科学活动是社会性的，技术研究必须对其可能造成的影响保持自觉。对未来的学习和研究而言，这些认识会继续提醒我：在面对复杂模型和快速变化的技术潮流时，既要保持探索的热情，也要保留怀疑的能力；既要尊重数据和实验，也要看到数据背后的现实关系；既要追求技术进步，也要把人的需要和社会责任放在视野之内。

自然辩证法并不是远离专业研究的抽象理论。它恰恰可以在一次具体实验、

一次失败复现、一次错误样本分析中显现出来。现代科学越是依赖复杂工具，越需要研究者具备反思工具的能力；技术越是具有社会影响，越需要研究者理解自身工作的公共意义。那次经历让我明白，科研不是把答案从模型里取出来，而是在实践中不断辨析现象、证据、解释和价值之间的关系。对我而言，这正是自然辩证法在人工智能研究中的现实意义。

### **参考文献**

- [1] 恩格斯. 自然辩证法[M]. 北京: 人民出版社, 2018.
- [2] Popper K. The Logic of Scientific Discovery[M]. London: Routledge, 2002.
- [3] Kuhn T S. The Structure of Scientific Revolutions[M]. 4th ed. Chicago: University of Chicago Press, 2012.
- [4] Merton R K. The Sociology of Science: Theoretical and Empirical Investigations[M]. Chicago: University of Chicago Press, 1973.
- [5] Bender E M, Gebru T, McMillan-Major A, et al. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?[C]//Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. New York: ACM, 2021: 610-623.
- [6] Mitchell M. Artificial Intelligence: A Guide for Thinking Humans[M]. New York: Farrar, Straus and Giroux, 2019.